


BỘ TÀI NGUYÊN VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC TÀI NGUYÊN VÀ MÔI
TRƯỜNG TP.HCM



NGÀNH CÔNG NGHỆ THÔNG TIN
MÔN HỌC: NHẬP MÔN TRÍ TUỆ NHÂN TẠO

**Xây Dựng Mô Hình Phân Tích
Luật Kết Hợp Giỏ Hàng Trực Tuyến**

Sinh viên thực hiện :

1250080140 - Đỗ Hoàng Phi
1250080164 - Trần Lê Phước Tài
1250080159 - Mai Phước Sang

Giảng viên hướng dẫn:

Ths. Nguyễn Duy Tuấn
CN. Nguyễn Phan Chí
Thành

TÓM TẮT DỰ ÁN

Trong bối cảnh bùng nổ của thương mại điện tử, việc tối ưu hóa trải nghiệm người dùng và tăng cường doanh thu thông qua các hệ thống gợi ý là vô cùng quan trọng. Báo cáo này trình bày nghiên cứu và xây dựng mô hình Phân tích Giỏ hàng (Market Basket Analysis) sử dụng thuật toán Apriori trên bộ dữ liệu giao dịch thực tế của một nền tảng bán lẻ.

Nghiên cứu tập trung vào việc tiền xử lý dữ liệu lớn (hơn 69,000 giao dịch), khai phá các tập sản phẩm phổ biến và trích xuất các luật kết hợp có ý nghĩa dựa trên các độ đo học máy bao gồm Support, Confidence và Lift. Kết quả thực nghiệm cho thấy mô hình có khả năng phát hiện chính xác các nhóm sản phẩm thường được mua cùng nhau (như sự liên kết mạnh mẽ giữa các sản phẩm quần áo thương hiệu New Balance, Nike, Under Armour). Dựa trên kết quả này, báo cáo đề xuất các chiến lược kinh doanh cốt lõi như sắp xếp gian hàng trực tuyến, xây dựng hệ thống recommendation (gợi ý) và thiết kế các gói sản phẩm combo hiệu quả.

Contents

TÓM TẮT DỰ ÁN	i
1 GIỚI THIỆU VÀ PHÁT BIỂU BÀI TOÁN	1
1.1 Lý do chọn đề tài	1
1.2 Phát biểu bài toán	1
2 CƠ SỞ LÝ THUYẾT CHI TIẾT	1
2.1 Phân tích giỏ hàng (Market Basket Analysis)	1
2.2 Cấu trúc toán học của Luật kết hợp	1
2.3 Thuật toán Apriori	2
3 MÔ TẢ DỮ LIỆU VÀ TIỀN XỬ LÝ	2
3.1 Mô tả tập dữ liệu	2
3.2 Tiền xử lý và Xây dựng Basket Matrix	2
4 PHÂN TÍCH KHÁM PHÁ VÀ KẾT QUẢ THỰC NGHIỆM	3
4.1 Khai phá tập mục phổ biến (Frequent Itemsets)	3
4.2 Khai phá Luật kết hợp (Association Rules)	3
4.3 Trực quan hóa Dữ liệu	4
5 MÔ PHỎNG HỆ THỐNG GỢI Ý (RECOMMENDATION SYSTEM)	4
6 ĐỀ XUẤT CHIẾN LƯỢC KINH DOANH VÀ KẾT LUẬN	5
6.1 Tối ưu hóa Giao diện (Recommendation Engine)	5
6.2 Chiến lược Bundle Pricing (Bán theo gói Combo)	5
6.3 Kết luận	6

1 GIỚI THIỆU VÀ PHÁT BIỂU BÀI TOÁN

1.1 Lý do chọn đề tài

Trong thời đại số hóa, dữ liệu được ví như "dầu mỏ" của doanh nghiệp. Các sàn thương mại điện tử lớn như Amazon, Shopee hay Tiki đã thành công rực rỡ nhờ vào việc thấu hiểu hành vi khách hàng thông qua dữ liệu lịch sử mua sắm. Kỹ thuật Phân tích giỏ hàng (Market Basket Analysis - MBA) là một trong những ứng dụng kinh điển của Trí tuệ nhân tạo và Khai phá dữ liệu (Data Mining), giúp giải mã mối quan hệ tiềm ẩn giữa các mặt hàng trong cùng một đơn hàng.

1.2 Phát biểu bài toán

Mục tiêu của nghiên cứu này là xây dựng hệ thống phân tích hành vi mua sắm từ dữ liệu giao dịch. Cụ thể, bài toán đặt ra là cần tìm ra các luật kết hợp dạng $X \Rightarrow Y$ (Nếu khách hàng mua X thì khả năng mua Y là bao nhiêu) để từ đó:

- Tối ưu hóa việc sắp xếp giao diện hiển thị và tính năng "Gợi ý mua kèm".
- Hỗ trợ bộ phận Marketing thiết lập chiến lược Bundle Pricing (bán hàng theo gói combo).
- Nâng cao tỷ lệ chuyển đổi đơn hàng và tăng doanh thu bán chéo (Cross-selling).

2 CƠ SỞ LÝ THUYẾT CHI TIẾT

2.1 Phân tích giỏ hàng (Market Basket Analysis)

Phân tích giỏ hàng hoạt động dựa trên nguyên lý xác suất thống kê. Nếu một tập hợp lớn khách hàng có thói quen mua sản phẩm A cùng với sản phẩm B, hệ thống có thể học được quy luật này để áp dụng cho các khách hàng mới trong tương lai. Điều này không chỉ giúp tăng doanh số bán chéo mà còn tối ưu hóa chuỗi cung ứng.

2.2 Cấu trúc toán học của Luật kết hợp

Giả sử $I = \{i_1, i_2, \dots, i_m\}$ là tập hợp các mặt hàng (Items) và D là cơ sở dữ liệu các giao dịch (Transactions). Một luật kết hợp có dạng $X \Rightarrow Y$, trong đó $X, Y \subset I$ và $X \cap Y = \emptyset$. Hiệu quả của một luật được đo lường bằng 3 chỉ số chính:

1. **Support (Độ hỗ trợ):** Tần suất xuất hiện đồng thời cả X và Y trong toàn bộ tập dữ liệu D :

$$Support(X \Rightarrow Y) = P(X \cup Y) = \frac{\text{Số giao dịch chứa cả X và Y}}{\text{Tổng số giao dịch}} \quad (1)$$

2. **Confidence (Độ tin cậy):** Khả năng sản phẩm Y được mua khi khách hàng đã quyết định mua X:

$$Confidence(X \Rightarrow Y) = P(Y|X) = \frac{Support(X \cup Y)}{Support(X)} \quad (2)$$

3. **Lift (Độ nâng):** Chỉ số quan trọng nhất để đánh giá mức độ tương quan thực sự giữa X và Y, loại bỏ đi sự ngẫu nhiên. Nếu $Lift > 1$, X và Y có tương quan dương (hỗ trợ nhau bán ra):

$$Lift(X \Rightarrow Y) = \frac{Confidence(X \Rightarrow Y)}{Support(Y)} \quad (3)$$

2.3 Thuật toán Apriori

Apriori là thuật toán kinh điển để khai phá tập phổ biến. Điểm mấu chốt của thuật toán là tính chất *Downward Closure*: "Nếu một tập mục là phổ biến, thì tất cả các tập con của nó cũng phải phổ biến". Điều này giúp thuật toán cắt tỉa (pruning) không gian tìm kiếm khổng lồ, giảm thiểu thời gian tính toán đáng kể so với việc duyệt vét cạn.

3 MÔ TẢ DỮ LIỆU VÀ TIỀN XỬ LÝ

3.1 Mô tả tập dữ liệu

Bộ dữ liệu được sử dụng mang tên "Online Retailer Data.xlsx". Tổng số giao dịch ghi nhận được là 69,593 cuộc giao dịch khác nhau với tổng cộng 77 mặt hàng phân bố trên các thương hiệu lớn như Adidas, New Balance, Nike, Under Armour.

Bảng dưới đây trích xuất 5 dòng dữ liệu thô đầu tiên để nắm bắt cấu trúc:

STT	TransactionID	CustomerID	Order _Date	Brand	Product	Color	Size	Sales _Amount
0	586916	666668	2020-04-16	Under Armour	V-Neck	NEON	32	14
1	586916	666668	2020-04-16	Under Armour	Shorts	BRIGHT PINK	24	3
2	589601	666714	2020-04-16	Under Armour	Sports Bra	WHITE	44B	56
3	589357	666742	2020-04-16	New Balance	Polo	NAVY	2X LARGE	27
4	589357	666742	2020-04-16	New Balance	Crewneck	WHITE	LARGE	53

Table 1: Cấu trúc 5 dòng dữ liệu thô ban đầu

3.2 Tiền xử lý và Xây dựng Basket Matrix

Thuật toán Apriori không thể đọc trực tiếp dữ liệu dạng bảng dài. Do đó, bước tiền xử lý yêu cầu chuyển đổi dữ liệu thành Ma trận giỏ hàng (Basket Matrix), sử dụng kỹ thuật One-Hot Encoding. Dưới đây là đoạn mã Python sử dụng thư viện *pandas*:

```

1 import pandas as pd
2
3 # Tạo cột 'Item' bằng cách ghép Thương hiệu và Sản phẩm
4 df['Item'] = df['Brand'] + ' ' + df['Product']
5
6 # Tạo ma trận giỏ hàng (Basket Matrix)
7 basket = (df.groupby(['TransactionID', 'Item'])['Item']
8           .count().unstack().reset_index().fillna(0)
9           .set_index('TransactionID'))
10
11 # Chuyển đổi số lượng thành 0 và 1 (One-Hot Encoding)
12 def encode_units(x):
13     if x == 0:

```

```

14         return 0
15     if x >= 1:
16         return 1
17
18 basket_sets = basket.map(encode_units)
19 print(f"Kích thước ma trận: {basket_sets.shape}")

```

Listing 1: Quy trình xây dựng Ma trận giỏ hàng (Basket Matrix)

Sau khi biến đổi, hệ thống thu được ma trận nhị phân khổng lồ có kích thước **69,593 hàng** $\times$ **168 cột**, mỗi hàng tương ứng với một mã đơn hàng và mỗi cột biểu diễn trạng thái mua/không mua (1/0) của từng mặt hàng cụ thể.

4 PHÂN TÍCH KHÁM PHÁ VÀ KẾT QUẢ THỰC NGHIỆM

4.1 Khai phá tập mục phổ biến (Frequent Itemsets)

Áp dụng thuật toán Apriori với tham số `min_support = 0.005`, hệ thống đã trích xuất được danh sách các sản phẩm bán chạy nhất.

Table 2: Top 5 tập sản phẩm phổ biến nhất

Sản phẩm (Itemsets)	Độ hỗ trợ (Support)	Tỷ lệ (%)
New Balance Crewneck	0.1969	19.69%
Nike Underwire	0.1330	13.30%
Silkies Pantyhose	0.0652	6.52%
New Balance Pants	0.0623	6.23%
New Balance V-Neck	0.0608	6.08%

Sản phẩm "New Balance Crewneck" xuất hiện trong gần 20% tổng số các cuộc giao dịch, chứng tỏ đây là sản phẩm "mỏ neo" thu hút lượng lớn khách hàng.

4.2 Khai phá Luật kết hợp (Association Rules)

Để đảm bảo luật có giá trị thực tiễn, nhóm đã thiết lập bộ lọc: $Lift > 0.02$ và $Confidence \geq 0.01$.

Table 3: Chi tiết các luật kết hợp có độ Nâng (Lift) mạnh nhất

Vế trái (Khách đã mua)	Vế phải (Khách sẽ mua)	Support	Confidence	Lift
Under Armour V-Neck	Under Armour Crewneck	0.0071	31.84%	11.95
New Balance Jacket	New Balance Pants	0.0064	28.67%	4.59
New Balance Pants	New Balance Crewneck	0.0247	39.64%	2.01
New Balance Shorts	New Balance Crewneck	0.0061	37.01%	1.87
New Balance V-Neck	New Balance Crewneck	0.0214	35.24%	1.78

Phân tích kết quả: Luật có độ tương quan mạnh nhất là cặp sản phẩm của *Under Armour* (Lift = 11.95). Tỷ lệ mua chung cao gấp gần 12 lần so với việc khách hàng mua ngẫu nhiên độc lập 2 món hàng.

4.3 Trực quan hóa Dữ liệu

Biểu đồ phân tán (Scatter Plot) dưới đây trực quan hóa không gian của các luật kết hợp.




Figure 1: Phân bố các quy tắc kết hợp dựa trên Support, Confidence và Lift (màu sắc)

Các điểm có màu sáng (vàng) đại diện cho $Lift > 2.0$, đây chính là "mỏ vàng" để các nhà tiếp thị tập trung ngân sách quảng cáo chéo nhằm tối ưu lợi nhuận.

5 MÔ PHỎNG HỆ THỐNG GỢI Ý (RECOMMENDATION SYSTEM)

Đây là bước ứng dụng thực tiễn quan trọng nhất của mô hình. Dựa trên bộ luật (Rules) đã được khai phá, nhóm đã xây dựng hàm `goi_y_san_pham` nhằm tự động gợi ý mua kèm khi khách hàng chọn một sản phẩm.

```

1 def goi_y_san_pham(ten_san_pham, tap_luat, so_luong_goi_y=3):
2     print(f"BAN VUA THEM VAO GIO HANG: {ten_san_pham}")
3     print("-" * 60)
4
5     # Tim cac luat ma Cot A (antecedents) chua san pham khach dang xem
6     luat_phu_hop = tap_luat[tap_luat['antecedents'].apply(lambda x
7 : ten_san_pham in str(x))]
```

```

8     # Sắp xếp các luật theo Do Nang (Lift) từ cao xuống thấp
9     luat_phu_hop = luat_phu_hop.sort_values(by='lift', ascending=
    False).head(so_luong_goi_y)
10
11     print("GOI Y MUA KEM (CO THE BAN SE THICH):")
12     for i, row in luat_phu_hop.iterrows():
13         mon_goi_y = list(row['consequents'])[0]
14         do_tin_cay = row['confidence'] * 100
15         do_nang = row['lift']
16
17         print(f"    -> {mon_goi_y}")
18         print(f"        (Ty le mua chung: {do_tin_cay:.1f}% | - Lift
    : {do_nang:.2f})")

```

Listing 2: Mã nguồn xây dựng hàm Gợi ý sản phẩm

Kết quả chạy thực tế của hệ thống: Khi khách hàng thêm sản phẩm *New Balance Jacket* vào giỏ, hệ thống lập tức xuất ra các gợi ý:

```

1 BAN VUA THEM VAO GIO HANG: New Balance Jacket
2 -----
3 GOI Y MUA KEM (CO THE BAN SE THICH):
4     -> New Balance Pants
5         (Ty le mua chung: 28.7% | - Lift: 4.60)
6     -> New Balance Crewneck
7         (Ty le mua chung: 32.2% | - Lift: 1.64)
8 -----

```

Listing 3: Kết quả gợi ý sản phẩm chạy trên Terminal

6 ĐỀ XUẤT CHIẾN LƯỢC KINH DOANH VÀ KẾT LUẬN

Dựa trên kết quả định lượng từ mô hình AI, nhóm nghiên cứu đề xuất các chiến lược thực tiễn sau:

6.1 Tối ưu hóa Giao diện (Recommendation Engine)

Xây dựng tính năng "Frequently Bought Together" (Thường được mua cùng nhau). Khi khách hàng click vào *New Balance Jacket*, hệ thống tự động hiển thị gợi ý *New Balance Pants*. Tính năng này có thể tự động tăng giá trị trung bình trên mỗi đơn hàng.

6.2 Chiến lược Bundle Pricing (Bán theo gói Combo)

Doanh nghiệp nên tạo các gói Combo "New Balance Starter Kit" bao gồm áo *Crewneck* và *Pants* với mức giá giảm 5% - 10%. Chiến lược này sử dụng sản phẩm "mỏ neo" (áo *Crewneck*) để thúc đẩy lượng bán của các sản phẩm vệ tinh khác.

6.3 Kết luận

Báo cáo đã hoàn thành xuất sắc mục tiêu xây dựng mô hình Phân tích giỏ hàng. Quy trình từ việc nắm bắt lý thuyết toán học của thuật toán Apriori, xử lý sạch gần 70,000 dòng dữ liệu giao dịch bằng thư viện *pandas*, cho đến việc trích xuất luật đã được thực hiện trọn vẹn. Mô hình hiện tại hoàn toàn đáp ứng được yêu cầu để đóng gói thành một Backend API, phục vụ đề xuất sản phẩm theo thời gian thực cho các nền tảng thương mại điện tử.

TÀI LIỆU THAM KHẢO

- [1] Agrawal, R., & Srikant, R. (1994). *Fast algorithms for mining association rules*. In Proceedings of the 20th International Conference on Very Large Data Bases (VLDB '94), 487-499.
- [2] Kaur, M., & Kang, S. (2016). *Market Basket Analysis: Identify the Changing Trends of Market Data Using Association Rule Mining*. Procedia Computer Science, 85, 78-85.
- [3] Raschka, S., & Mirjalili, V. (2019). *Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2*. Packt Publishing Ltd.
- [4] Raschka, S. (2018). *MLxtend: Providing machine learning and data science utilities and extensions to Python's scientific computing stack*. Journal of Open Source Software, 3(24), 638.
- [5] Han, J., Pei, J., & Yin, Y. (2000). *Mining frequent patterns without candidate generation*. ACM SIGMOD Record, 29(2), 1-12.